

Arsitektur U-Net Pada Segmentasi Citra Paru Untuk Mendeteksi Nodul Paru

Ermatita^{*1}, Wahyu Ningsih²

^{1,2}Fakultas Ilmu Komputer, Universitas Sriwijaya, Indonesia
Email: [1ermatitaz@yahoo.com](mailto:ermatitaz@yahoo.com), [2wahyuyuen87@gmail.com](mailto:wahyuyuen87@gmail.com)

Abstrak

Arsitektur U-Net dirancang untuk mengatasi kendala jumlah data yang terbatas, terutama dalam bidang medis. Dengan struktur encoder-decoder yang simetris, U-Net mampu mengekstraksi fitur penting dari citra input melalui encoder dan merekonstruksi citra sambil mempertahankan detail spasial melalui koneksi skip. Dalam segmentasi citra paru, U-Net digunakan untuk mendeteksi dan memetakan nodul paru secara otomatis dari CT scan. Penerapan U-Net diharapkan dapat mengurangi beban kerja ahli radiologi, meningkatkan konsistensi diagnosis, dan mempercepat proses deteksi nodul. Pada penelitian ini, U-Net mencapai akurasi sebesar 94% dalam segmentasi nodul paru.

Kata kunci: *Citra, Nodul Paru, U-Net*

U-Net Architecture In Lung Image Segmentation To Detect Lung Nodules

Abstract

The U-Net architecture is designed to address the challenge of limited data, especially in the medical field. With its symmetric encoder-decoder structure, U-Net effectively extracts key features from input images through the encoder and reconstructs images while preserving spatial details using skip connections. In lung image segmentation, U-Net is utilized to automatically detect and map lung nodules from CT scans. Its application aims to reduce radiologists' workload, enhance diagnostic consistency, and accelerate nodule detection. In this study, U-Net achieved an accuracy of 94% in lung nodule segmentation.

Keywords: *Image, pulmonary nodules, U-Net*

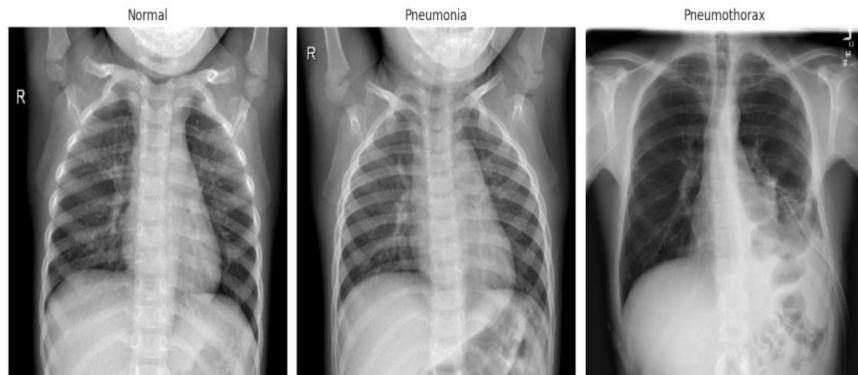
1. PENDAHULUAN

Menurut WHO, kanker paru merupakan salah satu penyakit dengan angka kematian tertinggi setiap tahunnya[1]. Kanker paru seringkali tidak menunjukkan gejala awal, oleh karena itu perlunya diagnosis dan pengobatan dini. Pemeriksaan kesehatan rutin dan penggunaan teknologi medis mutakhir sangat penting dalam meningkatkan peluang kelangsungan hidup dan kualitas hidup pasien. Langkah-langkah penting seperti meningkatkan kesadaran akan faktor risiko, memberikan pengobatan yang efektif, dan mengembangkan teknologi diagnostik yang lebih maju merupakan prioritas dalam mengatasi tantangan besar yang ditimbulkan oleh kanker paru-paru. Penyakit paru-paru, termasuk kanker paru-paru, merupakan salah satu penyebab utama kematian di seluruh dunia. Deteksi dini kanker paru-paru dapat secara signifikan meningkatkan peluang kesembuhan pasien. Salah satu metode utama dalam deteksi dini ini adalah dengan menggunakan citra medis, seperti CT scan, untuk mengidentifikasi nodul paru yang berpotensi menjadi kanker. Namun, interpretasi citra medis secara manual oleh ahli radiologi memerlukan waktu dan dapat menyebabkan variasi hasil diagnosis yang tinggi karena faktor subjektivitas dan kelelahan manusia.

Beberapa penelitian mengenai deteksi kanker paru pada gambar CT scan dengan metode CNN, salah satunya adalah [2] yang membahas tentang klasifikasi kanker paru-paru dan usus besar menggunakan Convolutional Neural Network dengan menganalisis kondisi dan fungsi jaringan organ. Beberapa penelitian juga menunjukkan efektivitas berbagai metode segmentasi dan klasifikasi tumor, seperti pendekatan fuzzy c-means dan deep learning pada segmentasi tumor hati[3], [4], [5]. Dalam beberapa tahun terakhir, perkembangan teknologi *deep learning* telah memberikan solusi potensial untuk meningkatkan akurasi dan efisiensi deteksi nodul paru melalui otomatisasi proses segmentasi citra. Salah satu arsitektur *deep learning* yang menonjol dalam tugas segmentasi citra medis adalah U-Net. U-Net pertama kali diperkenalkan oleh Olaf Ronneberger et al. pada tahun 2015 dan telah menunjukkan kinerja yang luar biasa dalam berbagai tugas segmentasi citra medis, termasuk deteksi lesi dan organ[6]. Pendekatan berbasis deep learning, seperti yang ditunjukkan oleh Desiani et

al. (2021), menggunakan arsitektur CNN untuk segmentasi dan klasifikasi citra medis, telah terbukti meningkatkan akurasi diagnosis[7].

Menurut Oguz dan Etugrul (2023) U-net adalah teknik segmentasi gambar yang dikembangkan terutama untuk tugas segmentasi gambar[8]. Ciri-ciri ini memberi U-net utilitas tinggi dalam komunitas pencitraan medis dan telah menghasilkan adopsi U-net secara luas sebagai alat utama untuk tugas segmentasi dalam pencitraan medis. Keberhasilan U-net terbukti dalam penggunaannya yang luas di hampir semua modalitas gambar utama, dari pemindaian CT dan MRI hingga sinar-X dan mikroskopi. Lebih jauh, sementara U-net sebagian besar merupakan alat segmentasi, ada beberapa contoh penggunaan U-net dalam aplikasi lain. Mengingat potensi U-net masih meningkat, tinjauan pustaka naratif ini meneliti berbagai perkembangan dan terobosan dalam arsitektur U-net dan memberikan pengamatan tentang tren terkini. Kami juga membahas banyak inovasi yang telah maju dalam pembelajaran mendalam dan membahas bagaimana alat-alat ini memfasilitasi U-net. Selain itu, kami meninjau berbagai modalitas gambar dan area aplikasi yang telah ditingkatkan oleh U-net.



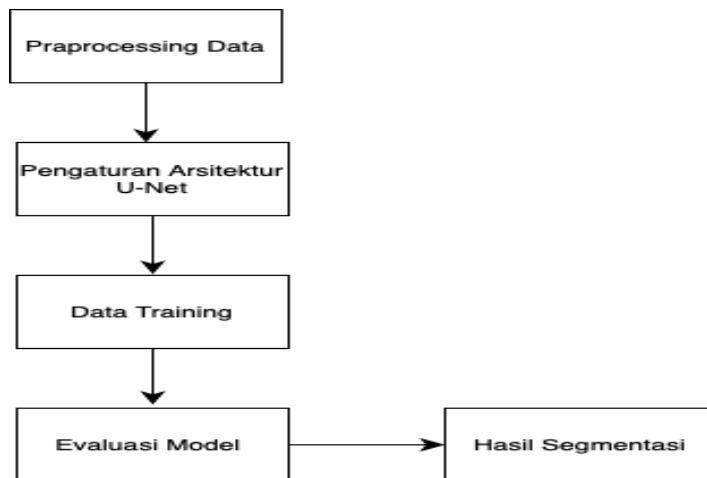
Gambar 1. Citra Paru

Arsitektur U-Net dirancang untuk bekerja dengan baik pada jumlah data yang relatif kecil, yang sering kali menjadi kendala dalam bidang medis. U-Net menggunakan struktur encoder-decoder simetris, di mana encoder mengekstraksi fitur penting dari citra input dan decoder merekonstruksi citra dari fitur-fitur tersebut sambil mempertahankan detail spasial yang tinggi melalui koneksi skip. Dalam konteks segmentasi citra paru, U-Net dapat digunakan untuk mendekripsi dan memetakan nodul paru secara otomatis dari CT scan. Penggunaan U-Net diharapkan dapat mengurangi beban kerja ahli radiologi, meningkatkan konsistensi diagnosis, dan mempercepat proses deteksi nodul paru.

Penelitian sebelumnya dilaksanakan oleh Zebua et.al (2024), membahas mengenai ResNet (Residual Neural Network) dalam deteksi gambar kanker paru karena kinerjanya yang luar biasa, berkat arsitekturnya yang mendalam, kemampuan pembelajaran fitur yang kuat, kemampuan generalisasi yang sangat baik, dan efektivitas yang konsisten yang ditunjukkan dalam berbagai penelitian[9]. Arsitektur mendalam ResNet memungkinkannya mengekstrak fitur rumit dari gambar kanker dengan presisi tinggi, bahkan dalam gambar beresolusi rendah atau berkualitas rendah. Kemampuan generalisasinya yang luar biasa memberdayakan model untuk bekerja secara efektif di beragam kumpulan data, yang mencakup berbagai variasi gambar kanker. Atribut-atribut ini menjadikan ResNet sebagai salah satu model pembelajaran mendalam yang paling menjanjikan untuk deteksi gambar kanker dan memiliki potensi besar untuk merevolusi diagnosis dan pengobatan kanker dini. Penelitian tersebut memiliki nilai akurasi sebesar 89%.

2. METODE PENELITIAN

Sub bab ini berisikan tahapan penelitian yang akan dilakukan. Penulis menggunakan bahasa pemrograman Python versi 3.7.13 melalui google colab dengan bantuan beberapa modul diantaranya seperti numpy, tensorflow, keras, matplotlib. Selain itu penulis juga menggunakan aplikasi Adobe Photoshop CS6 yang digunakan untuk memotong gambar area nodul kanker paru pada data CT Scan. Proses penelitian yang dilakukan dapat dilihat pada Gambar 1.



Gambar 1. Tahapan Penelitian

2.1. Preprocessing Data Machine Learnin

Sebelum mengolah data citra CT scan, terlebih dulu akan dilakukan proses awal yaitu *preprocessing* data. Tahapan *preprocessing* data ini bertujuan agar data citra CT scan sudah siap diolah ke tahapan selanjutnya. Dalam penelitian ini *preprocessing* yang dilakukan diantaranya adalah:

a. *Cropping*

Proses ini digunakan untuk membuang bagian citra yang tidak diperlukan sehingga dapat menambah fokus pada objek saat pengolahan. *Cropping* dilakukan terhadap data citra CT scan yang berukuran awal 512×512 piksel menjadi 64×64 piksel menggunakan *Adobe Photoshop CS6*.

b. *Konversi RGB ke grayscale*

Proses ini digunakan untuk mengkonversi seluruh citra CT scan RGB yang memiliki 3 channel (*Red*, *Green*, *Blue*) menjadi 1 channel (*Grayscale*).

c. Normalisasi

Proses ini digunakan untuk mentransformasi setiap nilai piksel menjadi sekumpulan nilai baru sehingga nilai mean akan mendekati 0 dan nilai standar deviasi akan mendekati 1.

d. Perbaikan Citra

Proses ini digunakan untuk meningkatkan kualitas citra CT scan dengan menghilangkan butiran-butiran warna yang mengganggu pada foto (*noise*) dengan median filter. Penggunaan metode berbasis histogram equalization telah terbukti meningkatkan kualitas citra medis dan mengurangi noise pada citra CT scan, sebagaimana diungkapkan oleh Riadi et al. (2020)[10]..

2.2. Pengaturan Hyperparameter

Setelah data siap diolah, selanjutnya perlu dilakukan pengaturan nilai *hyperparameter* untuk membuat model. Proses pengaturan nilai *hyperparameter* untuk mendapatkan model dengan performa optimal disebut *hyperparameter tuning*. Dalam penelitian ini, penulis akan mencari kombinasi nilai *hyperparameter* berdasarkan nilai *learning rate* dan *batch size* untuk menemukan kombinasi nilai *hyperparameter* optimal yang akan digunakan model. Semua kombinasi dari nilai *hyperparameter* diuji untuk mendapatkan pilihan yang optimal[5], [11]. Nilai *hyperparameter learning rate* dan *batch size* yang digunakan dalam penelitian ini sebagai berikut:

Tabel 1. Kombinasi Nilai *Hyperparameter Tuning*

<i>Hyperparameter</i>	Nilai
<i>Learning Rate</i>	(0.0001 ; 0.001 ; 0.01)
<i>Batch Size</i>	(8 ; 16 ; 32)

Dari Tabel 3.1 akan menghasilkan sembilan pasang kombinasi nilai *hyperparameter*, dimana masing-masing nilai tersebut diambil dari beberapa penelitian yang telah dilakukan dalam penelitian medical segmentasi [4], [12], [13]. Penelitian ini menggunakan *dice coefficient* sebagai metriknya sehingga kombinasi nilai *hyperparameter* yang menghasilkan nilai *dice coefficient* tertinggi yang akan terpilih sebagai nilai *hyperparameter* optimal untuk model..

2.3. Melatih Model Arsitektur U-Net

Setelah mengatur pemilihan nilai *hyperparameter*, akan dilakukan pembentukan arsitektur dari model yang digunakan. Sebelum itu, ditentukan terlebih dahulu *loss function* dan metode optimasi yang digunakan dalam penelitian. *Loss function* yang digunakan yaitu *Focal Tversky Loss* dengan memakai parameter dari penelitian sebelumnya [12] yaitu $\alpha = 0.7$, $\beta = 0.3$, dan sementara metode optimasi yang digunakan yaitu *Adam Optimizer*. Pembagian data pada penelitian ini untuk data train, data validasi dan data test berturut-turut yaitu 60%, 20%, dan 20%.

Arsitektur model yang digunakan dalam penelitian ini yaitu *Attention U-Net*. Model *Attention U-Net* adalah model yang hanya menyoroti aktivasi yang relevan selama pelatihan. Model ini dibangun dari arsitektur dasar *U-Net*, dimana pada setiap bagian skip koneksi *U-Net* diterapkan *attention gate*. Pada model *U-Net*, proses penggabungan info spasial atau skip koneksi membawa representasi fitur yang buruk karena pada lapisan awal representasi fitur cukup lemah. Oleh karena itu, peranan *attention gate* pada skip koneksi *U-Net* untuk memberi bobot lebih pada fitur yang menarik sehingga mampu menyoroti fitur-fitur yang menonjol. Arsitektur model *Attention U-Net* yang digunakan berdasarkan penelitian sebelumnya. dengan memakai jumlah saluran (16,32,64,128,256) dan akan membandingkannya dengan model *U-Net* dasar. Ilustrasi proses pelatihan model *Attention U-Net*.

Proses pelatihan model *Attention U-Net* dimulai dari input gambar berupa CT scan paru akan melewati jalur *downsampling* yang terdiri dari dua lapisan konvolusi (3×3) berturut-turut diikuti oleh ReLU dan satu lapisan *max pooling* (2×2) dengan *stride* dua. Pada proses *downsampling*, ukuran *feature maps* dibagi dua sementara jumlah *feature maps* digandakan dua kali lipat. Input awal pada penelitian ini memiliki ukuran $64 \times 64 \times 1$ setelah melewati jalur *downsampling* ukurannya berubah seterusnya secara bertahap sampai lapisan paling bawah menjadi $4 \times 4 \times 256$. Setelah melewati jalur *downsampling*, input terlebih dahulu akan melewati *attention gate* yang diterapkan pada setiap skip koneksi sebelum lanjut melewati jalur *upsampling*. Penjelasan skema kerja *attention gate* penelitian sebagai berikut:

- a. *Attention gate* memiliki dua input berupa x dan g .
- Input g berasal dari lapisan jaringan yang paling bawah. Input ini digunakan sebagai sinyal gating untuk meningkatkan pembelajaran input x karena memiliki representasi fitur lebih baik dan berasal dari jaringan yang lebih dalam.
- Input x berasal dari skip koneksi atau lapisan sebelumnya yang memiliki info spasial lebih baik tetapi tidak banyak info fitur.
- b. Selanjutnya dilakukan proses penggabungan input x dan input g .
- c. Kemudian hasil penggabungan input x dan input g akan melewati lapisan ReLU ($\text{ReLU}(z) = \max(0, z)$) untuk aktivasi dan melewati konvolusi 1×1 .
- d. Lalu input ini melewati lapisan sigmoid yang akan menskalakan bobot input diantara rentang $[0,1]$ yang menghasilkan koefisien *attention* () .
- e. Saat sudah memiliki kisaran bobot input $[0,1]$ selanjutnya akan dilakukan *Resampler* atau pengambilan sampel ulang untuk membuat ukurannya sama dengan ukuran x asli.
- f. Kalikan koefisien *attention* () dan vektor x asli dengan elemen-wise untuk mendapatkan output dari *attention gate*.

Output *attention gate* akan melewati jalur *upsampling*. Jalur ini terdiri dari satu lapisan *upsampling* (2×2), skip koneksi, dua lapisan konvolusi (3×3) berturut-turut dan satu tambahan konvolusi (1×1) untuk menghasilkan gambar yang tersegmentasi. Pada proses *upsampling*, ukuran *feature maps* digandakan dua kali lipat sementara jumlah *feature maps* dibagi dua. Ukuran dari output *attention gate* $8 \times 8 \times 128$ akan berubah seterusnya secara bertahap sampai lapisan paling atas menjadi $64 \times 64 \times 1$. Pelatihan pada penelitian ini menggunakan *4-fold cross validation*, dimana dilakukan pelatihan sebanyak empat kali dengan 30 epoch pada setiap model dan model yang memiliki nilai *loss* terkecil pada data validasi akan disimpan.

2.4. Evaluasi Setiap Model

Model yang sudah dilatih kemudian akan dievaluasi. Pada penelitian ini dilakukan evaluasi pada setiap model menggunakan pengukuran *dice coefficient*, *recall*, dan *precision* untuk melihat seberapa baik performa setiap model dalam mensegmentasi nodul kanker paru-paru. Kemudian dari hasil evaluasi tersebut akan dilihat kehadiran *attention gate* pada model *U-Net* apakah memberikan kinerja lebih baik dibandingkan model *U-Net*.

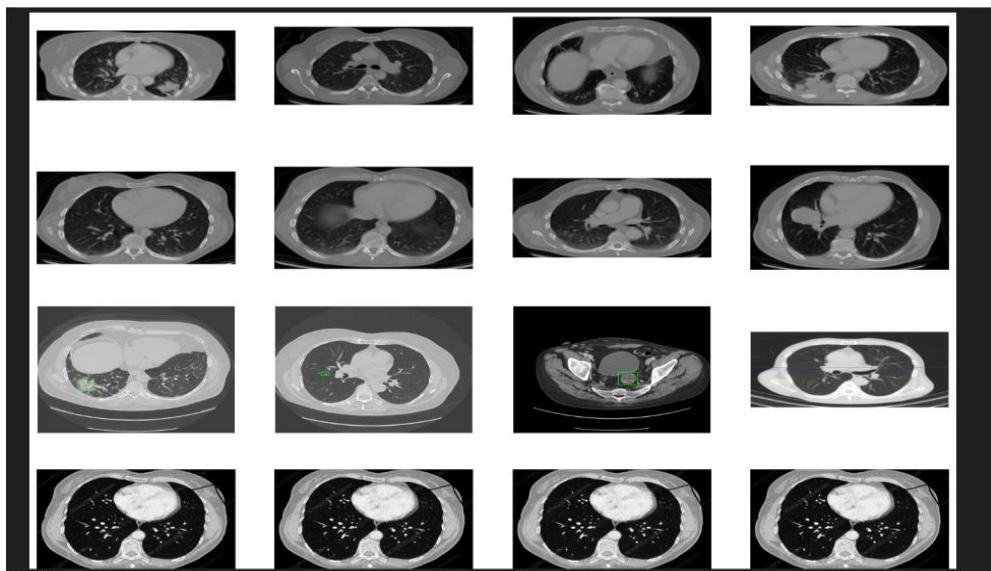
2.5. Hasil Segmentasi Gambar Nodul Setiap Model

Setelah dilakukan evaluasi, masing-masing model akan memberikan hasil segmentasi gambar nodul kanker paru-paru yang akan dibandingkan dengan *ground truth*, semakin mirip dengan *ground truth* maka akan semakin

baik. Kemudian dari hasil segmentasi gambar tersebut akan dilihat kehadiran *attention gate* pada model *U-Net* apakah mampu memberikan fokus lebih pada objek yang disegmentasi dibandingkan dengan model *U-Net*.

3. HASIL DAN PEMBAHASAN

Arsitektur U-Net diimplementasikan secara luas untuk segmentasi citra, terutama dalam domain medis, dengan langkah-langkah utama meliputi proses encoder untuk mengekstraksi fitur dari citra input, bottleneck untuk menyimpan informasi inti, dan decoder untuk merekonstruksi citra output yang tersegmentasi dengan menggabungkan fitur tingkat tinggi dan rendah melalui skip connection.

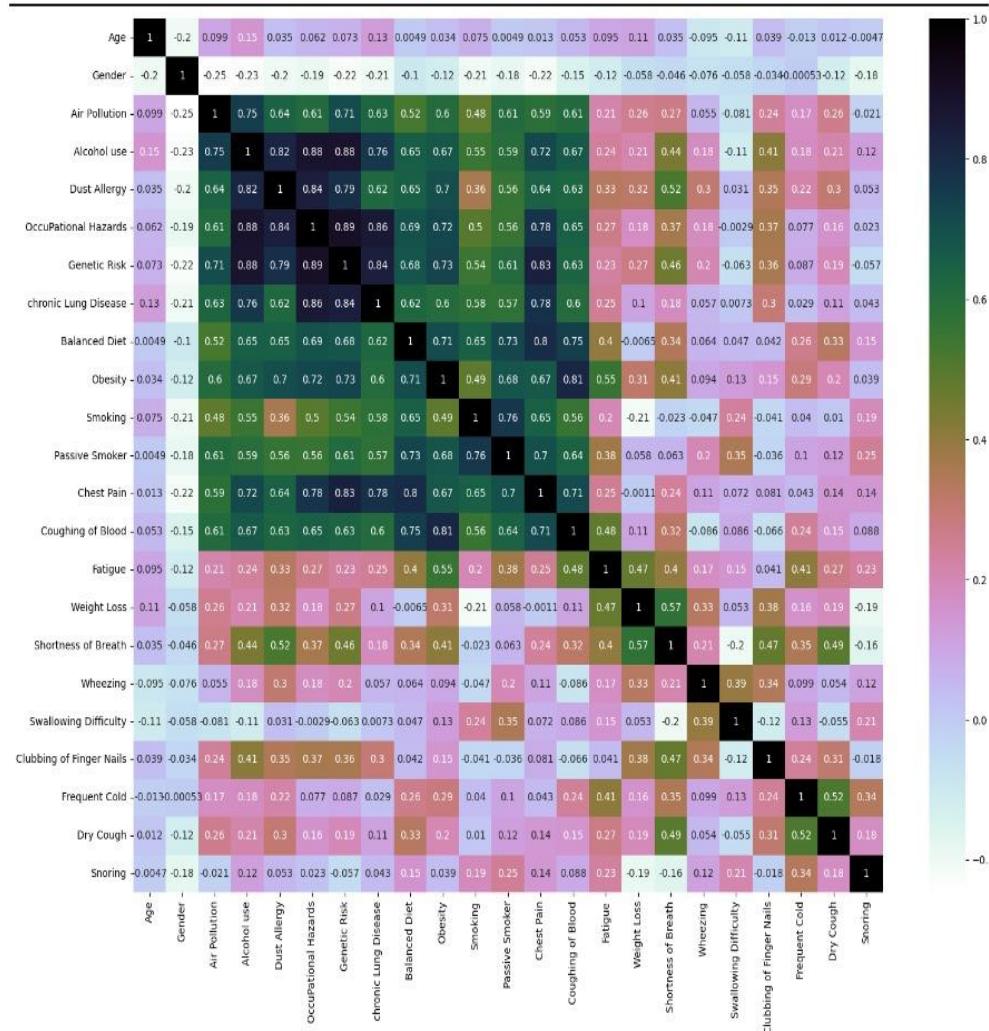


Gambar 2. Segmentasi Citra Paru

Gambar diatas merupakan sekumpulan citra medis (CT scan) yang relevan dengan segmentasi citra, seperti deteksi area tertentu dalam tubuh manusia. Dalam konteks ini arsitektur U-Net, proses ini dapat dijelaskan sebagai berikut:

1. **Input Citra:** Gambar-gambar medis (CT scan) diambil sebagai input. U-Net dirancang untuk menangani citra medis dengan resolusi tinggi.
 2. **Encoder:** Tahapan ini mencakup beberapa lapisan konvolusi dan pooling untuk mengekstrak fitur spasial dan mendeteksi pola pada gambar. Resolusi gambar diperkecil secara bertahap, namun jumlah fitur yang diekstraksi meningkat.
 3. **Bottleneck:** Di tengah jaringan, lapisan ini berfungsi untuk menangkap informasi yang paling penting dari citra, yang menjadi inti representasi fitur.
 4. **Decoder:** Lapisan ini bertanggung jawab untuk merekonstruksi kembali citra ke resolusi aslinya menggunakan lapisan dekonvolusi atau upsampling. Fitur dari encoder dihubungkan langsung ke decoder melalui skip connections, yang membantu mempertahankan informasi spasial.
 5. **Output Segmentation Map:** Hasil akhirnya adalah peta segmentasi yang menunjukkan area-area penting dari citra (misalnya, tumor atau struktur organ tertentu) dengan jelas. Dalam gambar yang ditampilkan, area yang ditandai (seperti kotak hijau) adalah hasil segmentasi untuk mendeteksi anomali atau fitur tertentu.
- Gambar yang diunggah menunjukkan heatmap korelasi antara berbagai variabel yang kemungkinan terkait dengan faktor risiko kesehatan atau kondisi medis tertentu. Berikut adalah penjelasan detailnya:
1. **Sumbu Horizontal dan Vertikal:** Setiap baris dan kolom mewakili satu variabel (misalnya, *Age*, *Gender*, *Air Pollution*, dll.). Variabel ini merupakan faktor risiko, gejala, atau atribut yang sedang dianalisis untuk saling keterkaitannya.
 2. **Nilai Korelasi :** Setiap sel pada heatmap menunjukkan koefisien korelasi antara dua variabel. Nilainya berkisar dari -1 hingga 1:
 3. **Warna di heatmap:** Warna di heatmap membantu memvisualisasikan intensitas hubungan.
 4. **Warna gelap (hitam):** Menunjukkan korelasi mendekati 1.
 5. **Warna terang (pink, hijau terang):** Menunjukkan korelasi lebih rendah atau negatif.
 6. **Interpretasi Nilai Korelasi:** *Air Pollution* memiliki korelasi tinggi (mendekati 1) dengan *Occupational Hazards* dan *Chronic Lung Disease*. Hal ini menunjukkan bahwa orang dengan paparan polusi udara juga

cenderung mengalami risiko pekerjaan atau penyakit paru-paru kronis. *Balanced Diet* memiliki korelasi negatif atau sangat rendah dengan beberapa gejala seperti *Smoking*atau *Chest Pain*. Ini mungkin menunjukkan bahwa pola makan sehat berbanding terbalik dengan kebiasaan buruk seperti merokok atau risiko penyakit tertentu.



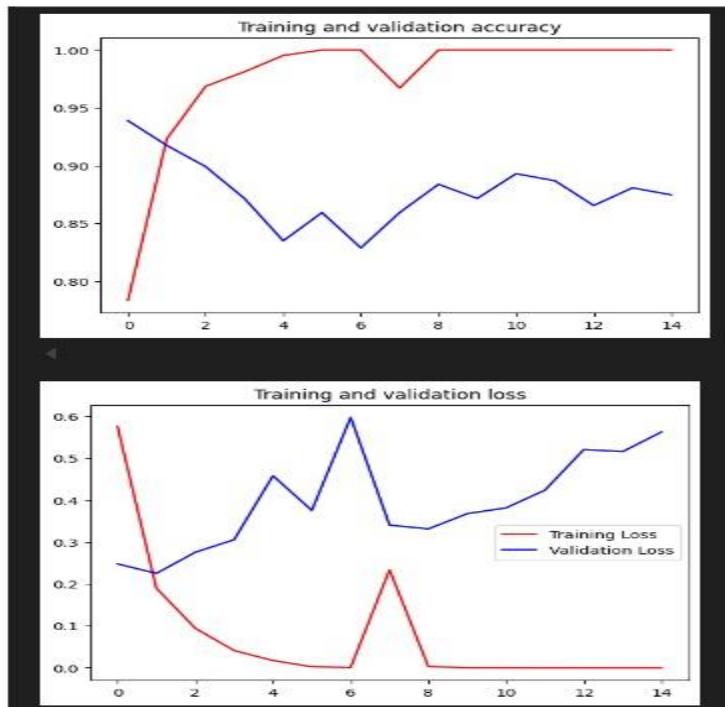
Gambar 3. Heatmat Korelasi

- Diagonal Utama: Semua nilai di diagonal utama memiliki korelasi 1 (hitam pekat), karena setiap variabel dibandingkan dengan dirinya sendiri.
- Penggunaan Heatmap: Analisis Risiko: Heatmap ini membantu mengidentifikasi faktor risiko atau hubungan yang signifikan untuk mendiagnosis atau memprediksi suatu kondisi medis.
- Reduksi Dimensi: Variabel dengan korelasi tinggi mungkin redundan, sehingga hanya sebagian variabel yang perlu dipertahankan untuk analisis lebih lanjut.
- Insight Klinis: Membantu memahami hubungan antara gejala, faktor lingkungan, dan perilaku.

Gambar tersebut menampilkan dua grafik yang memvisualisasikan performa model selama proses pelatihan dan validasi. Grafik atas menunjukkan akurasi pada data *training* (garis merah) dan *validation* (garis biru) sepanjang beberapa *epoch*. Akurasi *training* meningkat tajam dan mencapai nilai mendekati 1, menunjukkan bahwa model berhasil mempelajari pola pada data *training*. Namun, akurasi *validation* berfluktuasi dan tidak menunjukkan peningkatan signifikan, dengan perbedaan (gap) yang cukup besar dibandingkan dengan akurasi *training*. Hal ini mengindikasikan adanya overfitting, di mana model terlalu menyesuaikan diri dengan data *training* sehingga kurang mampu melakukan generalisasi pada data baru.

Sementara itu, grafik bawah menunjukkan nilai *loss* (kesalahan prediksi) pada data *training* (garis merah) dan *validation*(garis biru). *Training loss* menurun tajam, menunjukkan bahwa model berhasil meminimalkan kesalahan pada data *training*. Namun, *validation loss* mulai meningkat setelah beberapa *epoch*, menunjukkan

bahwa model menjadi kurang efektif dalam memprediksi data *validation*. Fenomena ini semakin menguatkan indikasi overfitting, di mana model mempelajari pola spesifik pada data *training* yang mungkin tidak relevan untuk data lain.



Gambar 4. Grafik Training dan Validasi

Untuk mengatasi masalah overfitting ini, beberapa strategi dapat diterapkan, seperti menggunakan teknik *regularization*(misalnya, dropout atau L2 regularization), memperbanyak data *training* dengan augmentasi, atau menggunakan *early stopping* untuk menghentikan pelatihan saat *validation loss* mulai meningkat. Selain itu, memilih model yang lebih sederhana juga dapat membantu jika dataset relatif kecil. Grafik ini menunjukkan pentingnya memantau performa model secara teratur untuk memastikan bahwa *training loss* dan *validation loss* memiliki tren yang konsisten tanpa perbedaan besar, yang idealnya mencerminkan kemampuan generalisasi model yang baik.

```

akurasi data training = 0.9471666666666667
akurasi data testing = 0.9443333333333334

confusin matrix :
[[3180  0]
 [ 334 2486]]

classification report :
      precision    recall  f1-score   support

          0       0.90      1.00      0.95     3180
          1       1.00      0.88      0.94     2820

   accuracy                           0.94      6000
  macro avg       0.95      0.94      0.94      6000
weighted avg       0.95      0.94      0.94      6000

```

Gambar 5. Hasil Accuracy Data

Pada Gambar 5, hasil prediksi menggunakan python menghasilkan akurasi sebesar 94%. Kebenaran area ground truth yang diberikan radiologist sangat penting karena menentukan tingkat akurasi dari gambar.

4. KESIMPULAN

Penelitian ini menunjukkan bahwa arsitektur U-Net memiliki performa yang sangat baik dalam mendeteksi nodul paru dengan tingkat akurasi mencapai 94%. U-Net, yang dirancang khusus untuk tugas segmentasi citra, mampu menangkap fitur spasial dan detail penting dari data citra medis. Hasil ini menunjukkan potensi besar U-Net sebagai alat bantu dalam diagnosis dini penyakit paru-paru, khususnya dalam mendeteksi nodul secara cepat dan akurat. Dengan akurasi yang tinggi, model ini dapat menjadi salah satu solusi andal untuk meningkatkan efisiensi serta kualitas layanan medis di bidang radiologi. Penelitian lebih lanjut diperlukan untuk menguji generalisasi model pada dataset yang lebih luas dan beragam, serta mengevaluasi integrasinya dalam praktik klinis.

DAFTAR PUSTAKA

- [1] World Health Organization, “Kanker Paru-paru,” World Health Organization. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/lung-cancer>
- [2] A. H. Uddin, Y.-L. Chen, M. R. Akter, C. S. Ku, J. Yang, and L. Y. Por, “Colon and lung cancer classification from multi-modal images using resilient and efficient neural network architectures,” *Heliyon*, vol. 10, no. 9, p. e30625, May 2024, doi: 10.1016/j.heliyon.2024.e30625.
- [3] M. Rela, N. R. Suryakari, and P. R. Reddy, “Liver Tumor Segmentation and Classification: A Systematic Review,” in *2020 IEEE-HYDCON*, Hyderabad, India: IEEE, Sep. 2020, pp. 1–6. doi: 10.1109/HYDCON48903.2020.9242757.
- [4] A. M. Anter and A. E. Hassenian, “CT liver tumor segmentation hybrid approach using neutrosophic sets, fast fuzzy c-means and adaptive watershed algorithm,” *Artif. Intell. Med.*, vol. 97, pp. 105–117, Jun. 2019, doi: 10.1016/j.artmed.2018.11.007.
- [5] M. Rela, S. Nagaraja, and P. Ramana, “Liver Tumor Segmentation using Superpixel based Fast Fuzzy C Means Clustering,” *Int. J. Adv. Comput. Sci. Appl.*, vol. 11, no. 11, 2020, doi: 10.14569/IJACSA.2020.0111149.
- [6] O. Ronneberg, P. Fischer, and T. Brox, “U-net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention—MICCAI 2015*, Cham, Switzerland: Springer International Publishing, 2015, pp. 234–241.
- [7] A. Desiani, Erwin, B. Suprihatin, S. Yahdin, A. I. Putri, and F. R. Husein, “Bi-path Architecture of CNN Segmentation and Classification Method for Cervical Cancer Disorders Based on Pap-smear Images,” *IAENG Int. J. Comput. Sci.*, vol. 48(3), pp. 1–10, 2021.
- [8] A. Oğuz and Ö. F. Ertuğrul, “Introduction to deep learning and diagnosis in medicine,” in *Diagnostic Biomedical Signal and Image Processing Applications with Deep Learning Methods*, Elsevier, 2023, pp. 1–40. doi: 10.1016/B978-0-323-96129-5.00003-2.
- [9] A. D. C. Zebua, D. Y. Marbun, F. Thedora, and M. Harahap, “Classification of Lung Cancer with Convolutional Neural Network Method Using ResNet Architecture,” *Teknika*, vol. 13, no. 2, pp. 318–323, Jul. 2024, doi: 10.34148/teknika.v13i2.906.
- [10] A. A. Riadi, A. A. Chamid, and A. Sokhibi, “Analisis Komparasi Metode Perbaikan Kontras Berbasis Histogram Equalization pada Citra Medis,” *Simetris J. Tek. Mesin Elektro Dan Ilmu Komput.*, vol. 8, no. 1, pp. 383–388, Apr. 2017, doi: 10.24176/simet.v8i1.1026.
- [11] N. Alalwan, A. Abozeid, A. A. ElHabshy, and A. Alzahrani, “Efficient 3D Deep Learning Model for Medical Image Semantic Segmentation,” *Alex. Eng. J.*, vol. 60, no. 1, pp. 1231–1239, Feb. 2021, doi: 10.1016/j.aej.2020.10.046.
- [12] J. Cai, “Segmentation and Diagnosis of Liver Carcinoma Based on Adaptive Scale-Kernel Fuzzy Clustering Model for CT Images,” *J. Med. Syst.*, vol. 43, no. 11, p. 322, Nov. 2019, doi: 10.1007/s10916-019-1459-2.
- [13] S. M. Anwar, S. Awan, S. Yousaf, and M. Majid, “Segmentation of Liver Tumor for Computer Aided Diagnosis,” in *2018 IEEE-EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, Sarawak, Malaysia: IEEE, Dec. 2018, pp. 366–370. doi: 10.1109/IECBES.2018.8626682.